

## 一、阅读范围

《统计学习方法》第九章 EM 算法及其推广

## 二、负责讲解部分主要知识梳理

### 9.1.1 例子（三硬币模型）

第九章第一节主要介绍的就是 EM 算法，EM 算法是一种迭代算法，用于含有隐变量的概率模型参数的极大似然估计，或极大后验概率估计。每次迭代过程包括 E (expectation)，求期望，和 M (maximization)，求极大，两步组成。

当概率模型中变量全是观测变量，给定数据我们可以直接用极大似然估计法，或贝叶斯估计法估计模型参数。但是当模型含有隐变量时，就不能简单地直接使用这些估计方法。这就是为什么要提出 EM 算法的原因。

9.1.1 中例子的作用是介绍与引入 EM 算法。

例 9.1（三硬币模型） 假设有 3 枚硬币，分别记作 A, B, C。这些硬币正面出现的概率分别是  $\pi$ ,  $p$  和  $q$ 。进行如下掷硬币试验：先掷硬币 A，根据其结果选出硬币 B 或硬币 C，正面选硬币 B，反面选硬币 C；然后掷选出的硬币，掷硬币的结果，出现正面记作 1，出现反面记作 0；独立地重复  $n$  次试验（这里， $n = 10$ ），观测结果如下：

1, 1, 0, 1, 0, 0, 1, 0, 1, 1

假设只能观测到掷硬币的结果，不能观测掷硬币的过程。问如何估计三硬币正面出现的概率，即三硬币模型的参数。

三硬币模型可以写作

$$\begin{aligned} P(y|\theta) &= \sum_z P(y, z|\theta) = \sum_z P(z|\theta)P(y|z, \theta) \\ &= \pi P^y(1-P)^{1-y} + (1-\pi)q^y(1-q)^{1-y} \end{aligned}$$

这里，随机变量  $y$  是观测变量，表示一次实验观测的结果是 1 或 0；随机变量  $z$  是隐变量，表示为观测到的掷硬币 A 的结果： $\theta = (\pi, p, q)$  是模型参数。这一模型是以上数据的生成模型。

也就是说，随机变量  $y$  的数据可以观测，随机变量  $z$  的数据不可观测。

进一步地，给出观测数据  $(Y = (Y_1, Y_2, \dots, Y_n)^T)$  的似然函数：

$$P(Y|\theta) = \prod_{j=1}^n [\pi p^{y_j}(1-p)^{1-y_j} + (1-\pi)q^{y_j}(1-q)^{1-y_j}]$$

考虑求模型  $\theta = (\pi, p, q)$  的极大似然估计，即

$$\hat{\theta} = \arg \max_{\theta} \log P(Y|\theta)$$

EM 算法首先选取参数的初值，记作  $\theta^{(0)} = (\pi^{(0)}, p^{(0)}, q^{(0)})$ ，然后通过 E, M 步迭代计算参数的估计值，直到收敛为止。第  $i$  次迭代参数的估计值为  $\theta^{(i)} = (\pi^{(i)}, p^{(i)}, q^{(i)})$ 。

EM 算法的第  $i+1$  次迭代如下。

E 步：计算在模型参数  $\pi^{(i)}, p^{(i)}, q^{(i)}$  下观测数据  $y_j$  来自掷硬币 B 的概率

$$\mu_j^{(i+1)} = \frac{\pi^{(i)}(p^{(i)})^{y_j}(1-p^{(i)})^{1-y_j}}{\pi^{(i)}(p^{(i)})^{y_j}(1-p^{(i)})^{1-y_j} + (1-\pi^{(i)})(q^{(i)})^{y_j}(1-q^{(i)})^{1-y_j}}$$

M 步：计算模型参数的新估计值：

$$\pi^{(i+1)} = \frac{1}{n} \sum_{j=1}^n \mu_j^{(i+1)}$$

$$p^{(i+1)} = \frac{\sum_{j=1}^n \mu_j^{(i+1)} y_j}{\sum_{j=1}^n \mu_j^{(i+1)}}$$

$$q^{(i+1)} = \frac{\sum_{j=1}^n (1 - \mu_j^{(i+1)}) y_j}{\sum_{j=1}^n (1 - \mu_j^{(i+1)})}$$

注：最终的结果与初值  $\theta^{(0)} = (\pi^{(0)}, p^{(0)}, q^{(0)})$  的选取有关。

三、下周预计读书进度

第十章 隐马尔可夫模型